

“Optimization”

Shervin Halat

98131018

Homework #2

1.

برابر است معادل بودن دو مسئله بهینه‌سازی کانیست؟ ثابت کنیم که هر feasible point از یک مسئله دارای یک feasible point متناظر در مسئله دیگر است به طوری که هر دو در تابع هدف مربعه‌ای (با یک مقدار مثبت) شوند.

(I) ابتدا فرض می‌کنیم x نقطه feasible در مسئله اول باشد، می‌خواهیم نشان دهیم که فقط متناظر به صورت $t = \frac{1}{c^T x + d}$ و $y = \frac{x}{c^T x + d}$ دارد که برای مسئله دوم feasible بوده و البته مقادیر تابع هدف هر دو نیز با هم برابر باشند.

$$\left. \begin{array}{l} x \rightarrow \text{feasible} \Rightarrow \begin{cases} f_0(x) \leq 0 \\ A x = b \end{cases} \\ y = \frac{x}{c^T x + d} \\ t = \frac{1}{c^T x + d} \end{array} \right\} \rightarrow x = \frac{y}{t} \Rightarrow \begin{array}{l} A x = b \rightarrow A \frac{y}{t} = b \rightarrow A y = b t \checkmark \\ f_0(x) \leq 0 \Rightarrow f_0\left(\frac{y}{t}\right) \leq 0 \xrightarrow{\times t} \frac{1}{t} f_0\left(\frac{y}{t}\right) \leq 0 \\ \Rightarrow g_0(y, t) \leq 0 \checkmark \end{array}$$

$$c^T x + d = c^T x + d \Rightarrow c^T x + d = \frac{1}{t} \Rightarrow c^T \frac{x}{t} + d t = 1 \Rightarrow c^T y + d t = 1 \checkmark$$

« این نشان دادیم که نقطه feasible متناظر هستند. حل باید نشان دهیم که هر دو در مقدار تابع هدف یکسان هستند. یعنی $g_0(y, t) = \frac{f_0(x)}{c^T x + d}$

$$g_0(y, t) = t f_0\left(\frac{y}{t}\right) = \frac{1}{c^T x + d} \times f_0(x) \checkmark \Rightarrow \text{این نشان دادیم از مسئله اول به دوم بر می‌آید.}$$

حال در جهت عکس اثبات را پیش می‌بریم یعنی از مسئله دوم به مسئله اول می‌بریم.

(II) حال فرض می‌کنیم که (y, t) نقطه feasible مسئله دوم است. سعی می‌کنیم به نقطه متناظر در مسئله اول برسیم. اگر داشته باشیم $x = \frac{y}{t}$ ، می‌خواهیم نشان دهیم که x نقطه feasible برای مسئله اول است به طوریکه متناظر (y, t) می‌باشد.

$$\left. \begin{array}{l} (y, t) \text{ feasible} \\ t > 0 \\ x = \frac{y}{t} \end{array} \right\} \rightarrow \begin{array}{l} Ay = bt \xrightarrow[t > 0]{\div t} A(\frac{y}{t}) = b \Rightarrow Ax = b \quad \checkmark \quad (I) \\ c^T y + dt = 1 \xrightarrow[t > 0]{\div t} c^T(\frac{y}{t}) + d = \frac{1}{t} \Rightarrow c^T x + d = \frac{1}{t} \Rightarrow \boxed{t = \frac{1}{c^T x + d}} \quad \checkmark \quad (II) \end{array}$$

$$g_i(y, t) \leq 0 \Rightarrow t f_i(\frac{y}{t}) \leq 0 \xrightarrow[t > 0]{\div t} f_i(x) \leq 0 \quad \checkmark \quad (III)$$

از (I), (II), (III) نتیجه می‌گیریم که در صورت feasible بودن (y, t) در مسئله دوم، $x = \frac{y}{t}$ نیز نقطه feasible برای مسئله اول خواهد بود. حال به برتر می‌پردازیم $g_0(y, t) \stackrel{?}{=} \frac{f_0(x)}{c^T x + d}$

$$g_0(y, t) = t f_0(\frac{y}{t}) \stackrel{(II)}{=} \frac{1}{c^T x + d} \times f_0(x) = \boxed{\frac{f_0(x)}{c^T x + d} = g_0(y, t)} \quad \checkmark$$

پس نشان داریم در حالت عکس نیز دو نقطه feasible متناظر به مقادیر تابع هدف یکسان متناظر می‌شوند. پس دو مسئله مورد نظر معادل می‌باشند. \checkmark

2.

با توجه به روابط مسئله معروفتر در صورت آسان است اینکه محدودیت مساوی
 $\text{Prob}(C^T x > \beta) \leq \alpha$ مربوط به یک تابع Convex است، با توجه به اینکه
 تقییر روابط همگی Affine هستند، محدب بودن مسئله آسان می گردد.

از روابط آمار داریم: $P(x \leq t) = \Phi\left(\frac{t - \mu}{\sigma}\right)$ Φ تابع CDF و $F_X(x)$ توزیع نرمال

$$\Phi(t) = P(X \leq t) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^t \exp\left\{-\frac{u^2}{2}\right\} du \quad (I)$$

که تابع Φ یک تابع پیوسته گسسته می باشد. (II)

حالا با فرض اینکه μ برابر $C_0^T x$ باشد (میانگین متغیر $C^T x$) و واریانس $C^T x$
 نیز برابر $x^T \Sigma x$ باشد، با توجه به رابطه (I) داریم:

$$\text{Prob}(C^T x > \beta) = \bar{\Phi}\left(\frac{\beta - C_0^T x}{\| \Sigma^{1/2} x \|}\right) \Rightarrow \text{Prob}(C^T x > \beta) \leq \alpha \Rightarrow$$

$$(\beta - C_0^T x) / \| \Sigma^{1/2} x \| \geq \bar{\Phi}^{-1}(\alpha) \Rightarrow \bar{\Phi}^{-1}(\alpha) \| \Sigma^{1/2} x \| + C_0^T x \leq \beta$$

هم چنین با توجه به رابطه (II) در صورتی $\bar{\Phi}^{-1}(\alpha) \geq 0$ می شود که $\alpha \leq 0.5$ باشد.

لذا با توجه به اینکه در فرض سؤال $\alpha = 0.01$ است که کوچکتر از 0.5 می باشد پس
 مسئله تعریف شده در سؤال یک مسئله Convex خواهد بود. ✓

3.

با فرض $\lambda, C \in \mathbb{R}^n$ ، با توجه به اینکه به ازای هر x_i ، محدودیت‌ها
مسئله کلاسیک مسئله حل شده، می‌توانیم به سادگی minimize کردن $C^T x = c_1 x_1 + \dots + c_n x_n$
در مجاری $c_i x_i$ را به طور جداگانه minimize کرد. یعنی

$$\text{minimize } c_i x_i$$

$$\text{s.t. } L_i \leq x_i \leq U_i$$

که برای این مسئله 3 حالت مختلف ممکن است به وجود آید با توجه به مقدار c_i

I) $c_i < 0$ در این حالت x_i بهینه برابر U_i خواهد بود.

$$L_i \leq x_i \leq U_i \xrightarrow{x_i} c_i x_i \geq c_i L_i \geq c_i U_i \Rightarrow \min(c_i x_i) = c_i U_i \Rightarrow \boxed{x_i = U_i}$$

II) $c_i > 0$

در این حالت x_i بهینه برابر L_i خواهد بود.

$$L_i \leq x_i \leq U_i \xrightarrow{x_i} c_i x_i \leq c_i U_i \leq c_i L_i \Rightarrow \min(c_i x_i) = c_i L_i \Rightarrow \boxed{x_i = L_i}$$

III) $c_i = 0$

در این حالت x_i بهینه یکت نخواهد بود چرا که در هر صورت $x_i \cdot c_i = 0$

در تمامی $L_i \leq x_i \leq U_i$ قابل قبول خواهند بود.

در نتیجه برای \min کردن $C^T x$ ، مقادیر بهینه x_i ها به قرار زیر اند:

$$x_i^* = \begin{cases} U_i & c_i < 0 \\ \text{don't care} & c_i = 0 \\ L_i & c_i > 0 \end{cases}$$

$$\Rightarrow \boxed{\text{optimal value } (P^*) = L^T C^+ + U^T C^- + 0} \checkmark$$

$$C_i^+ = \max\{c_i, 0\} \quad C_i^- = \min\{-c_i, 0\}$$

4.

رض می‌کنیم $y \in \mathbb{R}^n$ و $y = Ax - b$

$$\|Ax - b\|_1 = \|y\|_1$$

حل برای $\min \|y\|_1$ یا به عبارتی \min کردن جمع متقابل $\sum_{i=1}^n |y_i|$ کمیت هر یک از $|y_i|$ ها را \min کنیم.

چون می‌دانیم که مسئله متقابل $\min \|y\|_1$

معادل است با مسئله زیر:

$$\min t_i$$

$$\text{s.t. } |y_i| \leq t_i$$

که به منظور غنی کردن مسئله بالا، آن را به فرم زیر تغییر می‌دهیم:

$$|y_i| \leq t_i \Rightarrow y_i \leq t_i \text{ و } -y_i \leq t_i$$

$$\Rightarrow \min t_i$$

$$\text{s.t. } y_i \leq t_i$$

$$-y_i \leq t_i$$

$$\min t_i$$

$$\text{s.t. } a_i x + b_i \leq t_i$$

$$-a_i x - b_i \leq t_i$$

حال با قرار دادن t_i ها در یک بردار به نام T و در نظر گرفتن فرضیات بالا \Rightarrow به مسئله LP معادل زیر می‌رسیم:

$$\min T^T \cdot T$$

$$\text{s.t. } Ax + b \leq T$$

$$-(Ax + b) \leq T$$

همانطور که می‌بینیم تابع هدف و تمامی محدودیت‌ها همگی Affine هستند. ✓

5.

با توجه به فرضیات، رابطه‌های سؤال، فرض می‌کنیم که $y_j = x_j^2$ به طوری که $x, y \in \mathbb{R}^n$ در نتیجه $y_j \geq 0$ همچنین از آنجا که $x_j \geq 0$ در نتیجه رابطه برقرار است
 را به صورت $x_j = y_j^{\frac{1}{2}}$ بازنویس می‌کنیم. حال با جایگزینی $y_j^{\frac{1}{2}}$ در
 مسئله بهینه‌ساز روابط به فرم زیر تغییر می‌یابند:

$$f_i(x) = \frac{1}{2} x^T P_i x + q_i^T x + r_i \quad P_i \text{ is } z\text{-matrix}, \quad q_i \leq 0$$

$$= \frac{1}{2} (y^{\frac{1}{2}})^T P_i (y^{\frac{1}{2}}) + q_i^T y^{\frac{1}{2}} + r_i$$

$$= \frac{1}{2} \sum_{j=1}^n (P_i)_{jj} y_j + \frac{1}{2} \sum_{j \neq k} (P_i)_{jk} (y_j y_k)^{\frac{1}{2}} + \sum_{j=1}^n (q_i)_j y_j^{\frac{1}{2}} + r_i$$

(I)
(II)
(III)
(IV)

حال باید بررسی کنیم که $f_i(x)$ ها محدب باشند. برابر این کار کافیست نشان دهیم
 هر یک از ترم‌های رابطه بر حسب آماره بر حسب y_j به تنهایی محدب باشند:

(I) ✓ محاسبه می‌کند رابطه خطی است: $\frac{1}{2} \sum_{j=1}^n (P_i)_{jj} y_j$

(II) $\frac{1}{2} \sum_{j \neq k} (P_i)_{jk} (y_j y_k)^{\frac{1}{2}}$ نیز محدب بودن عبارت معادل:

باید ثابت کنیم $(y_j y_k)^{\frac{1}{2}}$ صفر است که آن به طور خلاصه در زیر آمده:

$$(y_j y_k)^{\frac{1}{2}} \rightarrow \begin{bmatrix} a & b \\ c & d \end{bmatrix} \text{ که } \begin{matrix} a, d \leq 0 \\ b, c \geq 0 \end{matrix}$$

با توجه به علامت‌های a, b, c, d می‌بینیم که $(-H)$ Strictly Diagonally Dominant

است پس خود (H) Negative Semi Definite است پس $(y_j y_k)^{\frac{1}{2}}$ مقعر می‌باشد.

پس رابطه (II) محدب است. ✓

حال با توجه به اینکه $y_i^{\frac{1}{2}}$ نیز صغر بوده و y_i ها نیز $\sum_{i=1}^n (y_i^{\frac{1}{2}})^2$ $\textcircled{\text{III}}$

منفی هستند پس رابطه $\textcircled{\text{III}}$ صدق است. ✓

$\textcircled{\text{IV}}$ y_i $\textcircled{\text{IV}}$

رابطه مقابل نیز به وضع صدق است. ✓

سر در نهایت $f_i(n)$ نیز حاصل جمع توانی صدق بوده و عدد صدق است.

پس مسئله را به مسئله $\textcircled{\text{A}}$ تابع هدف و توابع محدودیت $\textcircled{\text{A}}$ و $\textcircled{\text{B}}$ و $\textcircled{\text{C}}$ و $\textcircled{\text{D}}$ تبدیل کردیم یعنی $\textcircled{\text{A}}$ و $\textcircled{\text{B}}$ و $\textcircled{\text{C}}$ و $\textcircled{\text{D}}$ ✓

6.

با توجه به رابطه مشتق جیبی در α سطر کوچک داریم:

$$f(x_k + \alpha p) = f(x_k) + \alpha p^T \nabla f_k$$

سری برابر شدن دارد جهت کاهش کافیت $p^T \nabla f_k \leq 0$

$$\Rightarrow x_k = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \quad \nabla f_k = \begin{bmatrix} 2(x_1 + x_2^2) \\ 2(x_1 + x_2^2) \times 2x_2 \end{bmatrix} \quad p = \begin{bmatrix} -1 \\ 1 \end{bmatrix}$$

$$\Rightarrow p^T \nabla f(x_k) = \begin{bmatrix} -1 & 1 \end{bmatrix} \begin{bmatrix} 2 \\ 0 \end{bmatrix} = -2 \leq 0 \quad \checkmark$$

لذا جهت p به Direction Descent می باشد. \checkmark

حال برابر یافتن طول کم بهینه باید به دنبال minimize کردن رابطه زیر باشیم:

$$\phi(\alpha) = f(x + \alpha p) \quad \alpha > 0$$

$$\Rightarrow \phi(\alpha) = f\left(\begin{bmatrix} 1-\alpha \\ 0+\alpha \end{bmatrix}\right) = (1-\alpha + \alpha^2)^2 = \frac{(\alpha^2 - \alpha + 1)^2}{g(h(\alpha))} = \phi(\alpha)$$

$$\text{Convex} \leftarrow \phi(\alpha) \leftarrow \underbrace{h(\alpha) = \alpha^2 - \alpha + 1}_{\text{convex}} \quad \text{و} \quad \underbrace{g(\alpha) = 2\alpha}_{\text{nondecreasing for } \alpha > 0} \quad \text{و} \quad \underbrace{g(\alpha) = \alpha^2}_{\text{convex}} \quad \text{به طور کلی}$$

$$\Rightarrow \phi'(\alpha) = 0 \Rightarrow 2(\alpha^2 - \alpha + 1)(2\alpha - 1) = 0 \Rightarrow 2\alpha - 1 = 0 \Rightarrow \boxed{\alpha = \frac{1}{2}}$$

به طول کم بهینه برابر $\frac{1}{2}$ می باشد. \checkmark

7.

از روش بردار حلت استفاده می کنیم. فرض می کنیم بردارهای conjugate

$$\sum_{i=1}^n c_i P_i = 0 = c_1 P_1 + c_2 P_2 + \dots + c_n P_n = 0 \quad \text{مستقل خطی نباشند یعنی}$$

در نتیجه حداقل یک k ای وجود دارد که $c_k \neq 0$ باشد. (I)

حال طرفین تساوی بالا را در $P_k^T A$ ضرب می کنیم. با توجه به خواص بردارهای

conjugate خواهیم داشت:

$$\times P_k^T A \rightarrow c_1 \underbrace{P_k^T A P_1}_{=0} + \dots + c_k \underbrace{P_k^T A P_k}_{=0} + \dots + c_n \underbrace{P_k^T A P_n}_{=0} = 0$$

$$\Rightarrow \underbrace{c_k P_k^T A P_k}_{P_k^T A P_k > 0} = 0 \quad \left. \vphantom{\Rightarrow} \right\} \Rightarrow c_k = 0 \quad \times \quad \text{(II)}$$

Positive Definite

با فرض مستقل خطی نبودن به تناقض $c_k = 0$ رسیدیم. پس بردارهای conjugate مستقل خطی هستند.

به طور کلی تعداد جهت های conjugate نمی تواند از بُعد فضای مورد بحث بیشتر باشد.

چرا که حداکثر Rank یک ماتریس $n \times n$ برابر n می باشد که بیان کننده حداکثر تعداد بردارهای مستقل خطی در یک فضای n بعدی است. اثبات دیگر این امر در زیر آمده است.

فرض کنیم در فضای n بعدی، $n+1$ بردار مستقل خطی داریم آنگاه $Ax=0$ به طوری که

$$A = \begin{bmatrix} v_1 & v_2 & \dots & v_{n+1} \\ \vdots & \vdots & & \vdots \end{bmatrix} \quad \text{و} \quad A \text{ دارای بُعد } n \times (n+1) \text{ می باشد. پس معادله } Ax=0 \text{ دارای جهت های}$$

حداکثر n می باشد که اگر یکی از جملات $x_i \neq 0$ برابر با صفر نیست را در نظر بگیریم

$$Ax=0 \xrightarrow{x_i \neq 0} \sum_{j=1}^{n+1} a_{ij} x_j = 0 \Rightarrow \text{بردارها مستقل خطی نیستند.} \quad \times$$

پس فرض اولیه اشتباه بوده و حداکثر تعداد جهت های conjugate برابر n می باشد. ✓

8.

$$v_k = x_0 - x^* \quad (\text{eigenvector برابر ماتریس } Q)$$

فرض می‌کنیم

$$\Rightarrow Q(x_0 - x^*) = \lambda(x_0 - x^*) \quad (\text{I})$$

هم چنین می‌توانیم نام Q Quadratic Convex است پس داریم:

$$Qx^* = b \quad (\text{II})$$

هم چنین برابر روش $Line Search$ داریم:

$$x_1 = x_0 - \alpha \nabla f(x_0)$$

$$x_1 = x_0 - \alpha(Qx_0 - b) \xrightarrow{(\text{II})} x_1 - x_0 = -\alpha(Qx_0 - Qx^*)$$

$$\Rightarrow x_0 - x_1 = \alpha(Q(x_0 - x^*)) \xrightarrow{(\text{I})} x_0 - x_1 = \alpha\lambda(x_0 - x^*)$$

$$\Rightarrow x_0 - x_1 = \alpha'(x_0 - x^*) \quad (\text{III})$$

حال بایکجه به آنکه در رابطه (III) بدست آوردیم که از مبدأ x_0 ، هر دور x_1 و x^* در یک راستا قرار دارند و الگوریتم مورد استفاده $Line Search$ می‌باشد، در نتیجه x_1 می‌بایست با x^* برابر باشد در غیر اینصورت طول α محاسبه شده بهینه نبوده و این غیر ممکن است چرا که تابع مورد نظر $Convex$ بوده و لذا هر خط در آن نیز $Convex$ است و دارای یک مینیمم برابری می‌باشد.

$$\checkmark \quad \boxed{x_1 = x^*} \quad \text{لذا}$$